

Minería de Datos Masivos sobre el Yelp Open Dataset:

Grafos, Clustering, Recomendación Híbrida, Flujos y Reducción de Dimensionalidad

Christian Frisancho Camila Rodríguez Marcelo Zuloeta
Universidad de Ingeniería y Tecnología (UTEC) — Lima, Perú
{christian.frisancho, camila.rodriguez, marcelo.zuloeta}@utec.edu.pe

Abstract—Se presenta un pipeline integral de minería de datos masivos sobre el Yelp Open Dataset (6.9M reseñas, 150k negocios, 4.35 GB) [1], con todos los algoritmos implementados desde cero sobre numpy/pandas: muestreo estratificado y limpieza en un solo pase de streaming (Parte I), PageRank, HITS y detección de comunidades Louvain sobre el grafo de amistades (Parte II), clustering K-Means++ y DBSCAN de negocios (Parte III), un sistema de recomendación híbrido que combina filtrado colaborativo item-item y content-based TF-IDF (Parte IV), minería de flujos con ventanas deslizantes, Count-Min Sketch y Flajolet-Martin/LogLog (Parte V), y reducción de dimensionalidad con PCA y SVD truncada (Parte VI). Sobre una muestra estratificada de 2,943 negocios, 125,744 reseñas y 103,447 usuarios se obtiene, entre otros resultados: una componente conexa gigante de 41,832 usuarios donde PageRank correlaciona $r = 0.977$ con el grado de amistad; 140 comunidades con modularidad $Q = 0.656$; $k = 5$ clusters por silueta (0.167) frente a 190 outliers detectados por DBSCAN; NDCG@10 de 0.070 para el CF item-item ($2.4\times$ el baseline top-popular); un Count-Min Sketch que respeta su cota de error ϵN en el 100% de las claves usando $\sim 8\times$ menos memoria; y una SVD truncada a $k = 100$ factores que comprime $12\times$ reteniendo el 56% de la varianza. El informe cierra con un análisis crítico de escalabilidad (complejidad y benchmarks) y de las implicancias éticas de la personalización: concentración de la señal (Gini 0.666 en reseñas por negocio), spam y equidad entre cadenas y negocios independientes.

Index Terms—minería de datos masivos, PageRank, Louvain, K-Means++, DBSCAN, sistemas de recomendación, Count-Min Sketch, PCA, SVD, ética algorítmica

I. INTRODUCCIÓN

Las plataformas de opinión generan volúmenes masivos de datos con relaciones complejas: usuarios que se declaran amigos, reseñas con marca temporal, atributos de negocios y señales de asistencia (check-ins). Este proyecto aplica el ciclo completo de minería de datos masivos sobre el **Yelp Open Dataset** [1], elegido por tres razones: (i) contiene un grafo social explícito de amistades, indispensable para la Parte II; (ii) sus reseñas tienen marca temporal, lo que

permite simular un flujo de datos realista en la Parte V; y (iii) su tamaño (4.35 GB comprimidos, ~ 10 GB en JSON) obliga a tomar decisiones reales de muestreo y eficiencia.

Siguiendo la consigna del curso, **todas las técnicas se implementaron desde cero** —sin scikit-learn, networkx ni surprise— usando numpy y pandas únicamente como soporte numérico y tabular. El código está organizado en módulos (preprocessing.py, graphs.py, ranking.py, communities.py, kmeans.py, dbscan.py, recommenders.py, streaming.py, dimensionality_reduction.py, ethics.py) escritos y ejecutados desde siete notebooks en Databricks (ver Apéndice A).

Las secciones II–VIII corresponden a las Partes I–VII del proyecto: preprocesamiento y EDA, grafos y ranking, clustering, recomendación híbrida, flujos, reducción de dimensionalidad y análisis crítico-ético.

II. PREPROCESAMIENTO Y ANÁLISIS EXPLORATORIO

A. Muestreo estratificado y representatividad

El dataset crudo no cabe cómodamente en memoria, así que los cinco archivos JSON se procesan en *streaming* (línea por línea, un solo pase). Se construyó una **muestra estratificada por ciudad**: cada ciudad aporta negocios en proporción a su peso en el dataset completo (asignación proporcional, semilla fija 42), con un objetivo de 3,000 negocios. Luego se recuperan *todas* las reseñas, tips y check-ins de los negocios muestreados y todos los usuarios que los reseñaron. La representatividad queda garantizada por construcción: las proporciones por ciudad de la muestra son idénticas a las del dataset completo, y la distribución geográfica resultante (Fig. 2) cubre las áreas metropolitanas del dataset.

TABLE I: Tamaño de la muestra tras limpieza

Entidad	Filas	Observación
Negocios	2,943	objetivo 3,000, estratificado
Reseñas	125,744	2005–2022, texto y estrellas
Usuarios	103,447	17,027 <i>elite</i>
Check-ins	266,406	agregados por negocio
Tips	17,895	1 duplicado eliminado

B. Limpieza y decisiones de tratamiento

Las decisiones principales, aplicadas y documentadas en el reporte de limpieza del notebook:

- **Duplicados:** no hubo IDs duplicados; sí 4,658 pares (usuario, negocio) con múltiples reseñas, que se colapsaron a la más reciente (es la opinión vigente y evita que un mismo par pese doble en la matriz de utilidad).
- **Faltantes:** 1,274 negocios sin `price_range` (se imputa la mediana solo cuando la técnica lo requiere), 468 sin horario y 288 sin atributos (se conservan; la ausencia es informativa).
- **Outliers:** los negocios con `review_count` > p99 = 452 (30 casos) y los usuarios > p99 = 864 (1,033) se *marcan pero no se eliminan*: son power users y negocios virales reales, no errores de medición.
- **Validez:** 0 reseñas con rating inválido o texto vacío.

C. EDA: distribuciones y segmentos

Los ratings están sesgados hacia el extremo positivo (moda en 4–5 estrellas, forma de J característica de plataformas de opinión). La actividad, tanto de negocios como de usuarios, sigue **leyes de potencia** (Fig. 1): pocos negocios acumulan miles de reseñas mientras la mayoría tiene pocas, y el 88.1% de los usuarios escribió una sola reseña en la muestra —un dato que reaparece en las Partes IV y VII. Por segmentos, los usuarios *elite* (16.5%) escriben reseñas más largas y frecuentes, y los negocios abiertos promedian mejor rating que los cerrados.




Fig. 1: Leyes de potencia en la actividad: reseñas por negocio (izq.) y por usuario (der.), ambos ejes en escala log.




Fig. 2: Distribución geográfica de la muestra estratificada (color = estrellas promedio del negocio).

D. Grafos iniciales

Se construyeron dos grafos con listas de adyacencia propias (Tabla II). El grafo de amistades es extremadamente ralo y fragmentado: 60,644 componentes, con una **componente conexa gigante (LCC) de 41,832 usuarios (40.4%)** y diámetro aproximado 15 (BFS de doble barrido). Las Partes II–VII operan sobre estos artefactos.

TABLE II: Grafos iniciales de la muestra

	Bipartito U–N	Amistad U–U
Nodos	103,449 + 2,943	103,447
Aristas	125,744	305,776
Densidad	4.13×10^{-4}	5.71×10^{-5}
LCC	—	41,832 (40.4%)
Diámetro (aprox.)	—	15

III. ANÁLISIS DE GRAFOS Y RANKING

A. PageRank: influencia estructural

Se implementó PageRank iterativo [2] ($d = 0.85$, tolerancia 10^{-6}) sobre el LCC; convergió en 40 iteraciones. El ranking correlaciona fuertemente con el número de amistades dentro de la muestra ($r = 0.977$), moderadamente con los fans ($r = 0.479$) y débilmente con el volumen de reseñas ($r = 0.364$) (Fig. 3): PageRank mide *centralidad social*, no productividad. La cola derecha de la figura muestra además usuarios con PageRank mayor al que su grado explica: están conectados a otros nodos importantes, exactamente el efecto recursivo que distingue a PageRank del conteo de amigos.




Fig. 3: PageRank vs amistades en la muestra (izq., $r = 0.977$) y vs fans (der., $r = 0.479$).

B. HITS: hubs y authorities

HITS [3] se aplicó al grafo bipartito usuario–negocio (39 iteraciones): los usuarios actúan como *hubs* (apuntan a muchos negocios) y los negocios como *authorities* (reciben reseñas de buenos hubs). En este contexto, un hub es un **reseñador prolífico y diverso** y una authority es un **negocio validado por reseñadores expertos** —no simplemente el más reseñado: la correlación entre authority y `review_count` es solo 0.426, porque HITS pondera *quién* reseña, no cuántos.

Comparando rankings: PageRank (influencia social) y hub score (actividad reseñadora) miden dimensiones casi ortogonales de importancia, con correlación 0.023 y solapamiento de apenas 1/15 en sus top-15. Los “pilares de la red” —usuarios top en ambos lentes— son la excepción, no la regla.

C. Comunidades: Louvain

La detección de comunidades por optimización de modularidad (Louvain [4]) sobre el LCC encontró **140 comunidades con $Q = 0.6556$** , una estructura comunitaria fuerte. Las cinco mayores (Tabla III) agrupan al 66% del LCC y tienen densidad interna muy superior a la del grafo global; la comunidad 1 es la más “extrovertida” (41,197 aristas externas), actuando de puente. Dado que el muestreo es multi-ciudad, las comunidades capturan **círculos sociales y geográficos**: grupos de usuarios que se reseñan los mismos negocios locales y se declaran amistad entre sí (Fig. 4).

TABLE III: Cinco comunidades Louvain más grandes (de 140, $Q = 0.656$)

Com.	Tamaño	Aristas ext.	Miembros clave
0	8,891	17,030	Michelle, Steven, Morris
1	5,989	41,197	Abby, Phil, Randy
2	5,913	16,117	Kaitlyn, Christina, Brett
3	3,429	4,943	Niki, Brittany, Chad
4	3,411	7,040	Aaron, Aimee, Christy




Fig. 4: Núcleo conexo de las 6 comunidades mayores (layout force-directed propio; tamaño de nodo $\propto$ PageRank). Cada comunidad forma su “nube” con puentes escasos entre ellas.

IV. CLUSTERING DE NEGOCIOS

De las opciones de la Parte III se eligieron **K-Means++** y **DBSCAN**: el primero como método de referencia con selección rigurosa de k , y el segundo porque no asume clusters globulares y detecta outliers automáticamente, lo que da una comparación metodológicamente interesante (partición total vs. densidad).

A. Representación

Cada negocio se representa con 10 features *complementarias* estandarizadas (z-score): estrellas, dispersión del rating, volumen de reseñas/check-ins/tips en escala log, rango de precio, número de categorías, antigüedad, longitud media de reseña y estado (abierto/cerrado). Las 18 categorías top se agregan como dummies con **peso 0 durante el clustering** y se usan solo para describir los grupos resultantes, evitando que la segmentación sea un simple eco del rubro.

B. K-Means++ y selección de k

Se implementó K-Means++ [5] con la inicialización D^2 y selección de k por método del codo y coeficiente de silueta (Fig. 5). El codo es suave (la inercia decrece sin quiebre claro), pero la silueta es máxima en **$k = 5$** (0.1671), con tamaños [631, 439, 513, 436, 924]. Los perfiles dominantes: (0) gastronomía/vida nocturna consolidada, (1) negocios mixtos de menor supervivencia, (2) comercio y servicios activos, (3) negocios *cerrados* (0% abiertos: el clustering separó solo el ciclo de vida), y (4) servicios de bajo volumen de reseñas pero 100% abiertos.




Fig. 5: Método del codo (izq.) y silueta por k (der.): máximo en $k = 5$.

C. DBSCAN y detección de outliers

Los hiperparámetros se fijaron con el k -distance plot (Fig. 6): con $\text{minPts} = 10$, el codo de la curva sugiere $\varepsilon = 2.0$. DBSCAN [6] encontró **6 clusters y 190 outliers (6.5%)**. El cluster dominante (1,772 negocios abiertos) absorbe la masa central de densidad; los outliers son negocios con combinaciones extremas (volumen viral, longevidad inusual, dispersión de rating alta) —el lugar natural donde auditar posibles anomalías o spam (Sec. VIII).




Fig. 6: k -distance plot ($k = 10$): el codo alrededor de 2.0 fija ε .

D. Comparativa

TABLE IV: K-Means++ ($k = 5$) vs DBSCAN ($\varepsilon = 2.0$, $\text{minPts} = 10$)

Método	Clusters	Outliers	Silueta
K-Means++	5	0	0.1671
DBSCAN	6	190	0.0816

En la proyección PCA 2D (Fig. 7) se ve la razón de la diferencia: el espacio de features no tiene fronteras de densidad marcadas, así que DBSCAN colapsa la masa central en un solo grupo grande y su silueta cae a la mitad. **K-Means++ es mejor para segmentación de negocio; DBSCAN aporta lo que K-Means no puede: los 190 outliers.**




Fig. 7: Asignaciones de K-Means++ (izq.) y DBSCAN (der.) proyectadas a las dos primeras componentes principales (37% de la varianza).

V. SISTEMA DE RECOMENDACIÓN HÍBRIDO

A. Protocolo de evaluación

Split **temporal** por usuario (80/20, usuarios con ≥ 5 reseñas): 124,139 ratings de entrenamiento y 1,605 de prueba sobre 1,142 usuarios evaluables; la matriz de utilidad R ($103,449 \times 2,943$) tiene densidad 4.08×10^{-4} . Se evalúa predicción de rating (RMSE/MAE) y calidad de ranking (P@10, R@10, NDCG@10) contra dos baselines: aleatorio y top-popular.

B. Métodos

CF item-item: similitud coseno sobre ratings centrados por usuario, mínimo 3 co-ratings y poda a los 30 vecinos más similares; predicción por k -NN ponderado. Obtiene RMSE = 1.2128 y MAE = 0.8611 sobre los 409 ratings de test con vecindario disponible. **Content-based:** TF-IDF propio (vocabulario 2,000 términos, ≤ 50 reseñas por negocio) y perfil de usuario como promedio de los vectores de los negocios que reseñó positivamente. **Híbrido:** mezcla ponderada de scores normalizados, $s = \alpha \text{CF} + (1 - \alpha) \text{CB}$.

C. Resultados

TABLE V: Evaluación de ranking (891 usuarios con ítems relevantes en test)

Método	P@10	R@10	NDCG@10
Aleatorio (baseline)	0.0003	0.0028	0.0013
Top-popular (baseline)	0.0056	0.0461	0.0287
CF item-item	0.0177	0.1372	0.0699
Content-based (TF-IDF)	0.0042	0.0317	0.0186
Híbrido $\alpha = 0.5$	0.0136	0.0986	0.0599
Híbrido $\alpha = 0.7$	0.0143	0.1043	0.0607

El CF es el método más exacto ($54\times$ el NDCG del aleatorio y $2.4\times$ el top-popular). El barrido de α (Fig. 8) muestra el óptimo del híbrido en $\alpha = 0.6$: conviene dar mayor peso al CF pero conservar señal de contenido. El valor del híbrido no está en la precisión sino en la **cobertura**: ataca el problema de *cold-start*, ya que el CF no puede puntuar ítems sin co-ratings ni usuarios sin historial (el 88.1% de los usuarios tiene una sola reseña),

mientras que el content-based puntúa cualquier negocio con texto, incluso con una única reseña.




Fig. 8: NDCG@10 y Precision@10 del híbrido según α (peso del CF); óptimo en $\alpha = 0.6$.

VI. MINERÍA DE FLUJOS DE DATOS

Las 125,744 reseñas, ordenadas por timestamp (2005–2022), se procesan como un stream de eventos uno a la vez.

A. Ventanas deslizantes

Se implementaron ventanas de 1h, 4h y 24h con deque (expulsión de eventos viejos en $O(1)$ amortizado, memoria proporcional solo a la ventana). La Fig. 9 muestra count y promedio por ventana a lo largo de 17 años; los patrones agregados (Fig. 10) revelan un ciclo diario nítido (pico 17–22h, valle 4–9h), fines de semana más activos y estacionalidad con máximo en julio.



Fig. 9: Estadísticas dentro de cada ventana deslizante (1h/4h/24h): actividad (arriba, escala log) y rating promedio (abajo).



Fig. 10: Patrones temporales del stream: ciclo horario, semanal y estacional.

B. Count-Min Sketch: conteo aproximado con garantías

El CMS [7] con $\varepsilon = 10^{-3}$, $\delta = 0.01$ usa $5 \times 2,719 = 13,595$ contadores frente a las 103,449 claves de un conteo exacto ($\sim 8\times$ menos memoria). La garantía teórica —error $\leq \varepsilon N = 125.7$ con probabilidad $\geq 99\%$, y nunca subestima— se verificó empíricamente: **100% de las claves dentro de la cota**, error máximo 57 y medio 36.3. La Tabla VI muestra el tradeoff memoria–error al barrer ε .

TABLE VI: Count-Min Sketch: barrido de ε ($N = 125,744$)

ε	Celdas	Cota εN	Error medio	Dentro de cota
10^{-2}	1,360	1,257.4	430.5	100%
5×10^{-3}	2,720	628.7	208.4	100%
10^{-3}	13,595	125.7	36.3	100%
5×10^{-4}	27,185	62.9	16.2	100%

C. Técnica adicional: Flajolet–Martin / LogLog

Como técnica adicional se implementó el conteo de elementos distintos FM/LogLog [8], [9], justificada por la evidencia de la Parte I: con 103k usuarios y una distribución de cola pesada, mantener un set de IDs por periodo es costoso, mientras que **256 enteros** bastan para estimar usuarios únicos con error teórico $1.3/\sqrt{256} \approx 8\%$. En la corrida global estimó 108,095 distintos frente a 103,449 exactos (+4.5%), y por año el error relativo se mantuvo mayormente bajo 10% (salvo los primeros años con < 100 usuarios, donde el estimador probabilístico pierde sentido).

VII. REDUCCIÓN DE DIMENSIONALIDAD

A. PCA sobre las features de negocios

Sobre la matriz estandarizada de $2,943 \times 28$ (features de la Parte III, categorías incluidas) se calculó la matriz de covarianza y su eigendecomposición (**eigh**), validada contra la SVD de **numpy** (coincidencia numérica exacta). Se necesitan **20 de 28 componentes para explicar el 90.1%** de la varianza (Fig. 11): las features están poco correlacionadas (los dummies de categoría son casi ortogonales), así que no hay compresión drástica, pero las primeras PCs son interpretables: PC1 (12.9%) combina popularidad y gastronomía (**log_checkins** +0.40, **Restaurants** +0.39); PC2 (7.1%) es el eje de vida nocturna (**Nightlife** −0.42, **Bars** −0.42); PC3 (6.5%) separa comercio (**Shopping** +0.41, **Fashion** +0.34); PC4 (6.2%) opone calidad a antigüedad (**stars** −0.42, **business_age** +0.37). En la proyección 2D/3D coloreada por rating (Fig. 12) el gradiente de estrellas es visible pero continuo —consistente con la ausencia de clusters de densidad de la Parte III.




Fig. 11: Scree plot y varianza acumulada: 20 componentes alcanzan el 90%.




Fig. 12: Proyección PCA 2D y 3D de los negocios (color = estrellas).

B. SVD de la matriz TF-IDF: patrones latentes

La SVD se aplicó a la matriz TF-IDF negocio-término ($2,943 \times 2,000$). Los factores singulares son **temas latentes** legibles: gastronomía (pizza, food, chicken), cuidado personal (hair, salon, cut), automotriz (car, vehicle, wash), hotelería (pool, hotel, room) y comida mexicana (tacos, taco, burger). Truncando a k dimensiones se midió el tradeoff compresión-pérdida (Tabla VII, Fig. 13): con $k = 100$ se almacena **12× menos reteniendo el 56% de la varianza**, el codo económico de la curva; el texto libre es intrínsecamente de alta dimensión y recuperar el 80% ya exige $k = 400$.

TABLE VII: SVD truncada: reconstrucción de la matriz TF-IDF

k	Error relativo	Varianza capturada	Compresión
10	0.861	0.258	119×
50	0.739	0.454	24×
100	0.666	0.556	12×
400	0.451	0.797	3×




Fig. 13: Error de reconstrucción y varianza capturada vs k (SVD truncada).

VIII. ANÁLISIS CRÍTICO Y ÉTICO

A. Exactitud vs eficiencia y escalabilidad

La Tabla VIII resume la complejidad de los algoritmos implementados (n filas, d features, k clusters/factores, V/E nodos/aristas, N largo del stream, b negocios, t términos).

TABLE VIII: Complejidad y veredicto de escalabilidad

Algoritmo	Tiempo	Espacio	¿Escala?
Streaming + muestreo	$O(N)$	$O(\text{muestra})$	sí
PageRank	$O(it(V+E))$	$O(V+E)$	sí
HITS	$O(it \cdot E)$	$O(V+E)$	sí
Louvain	$\sim O(E \log V)$	$O(V+E)$	sí
Layout force-dir.	$O(it \cdot n^2)$	$O(n^2)$	no
K-Means++	$O(it \cdot nkd)$	$O(nd)$	sí (mini-batch)
DBSCAN (D densa)	$O(n^2d)$	$O(n^2)$	no
Silueta	$O(n^2)$	$O(n^2)$	no
Sim. item-item	$O(b^2m)$	$O(b^2)$	parcial
TF-IDF	$O(\text{docs} + bt)$	$O(bt)$ ralo	sí
Ventanas / CMS / FM	$O(1)/\text{evento}$	fija	sí
PCA (eigh)	$O(nd^2 + d^3)$	$O(d^2)$	sí (d chico)
SVD completa	$O(nt \min(n, t))$	$O(nt)$	parcial

Los benchmarks empíricos sobre la muestra cuantifican los tradeoffs: K-Means $k = 5$ con silueta tarda 0.17s y DBSCAN 0.09s, pero este último materializa una matriz de distancias de 69 MB; **con 300k negocios serían ~700 GB**, así que DBSCAN denso, la silueta y el layout $O(n^2)$ no escalan tal como están (en producción: índices espaciales, LSH o variantes sobre muestras). El CMS compra $\sim 8\times$ de memoria a cambio de +36 de error medio *acotado y unilateral*; la FM-LogLog reduce 103k IDs a 256 enteros con +4.5% de error; la SVD truncada comprime 12× perdiendo varianza medible *antes* de decidir k . Un matiz honesto: el conteo exacto con `dict` en C (0.02s) es más rápido que nuestro CMS en Python puro (0.63s); la ventaja del sketch es de **memoria y garantías** — y de que es un monoide fusionable entre nodos de un cluster —, no de velocidad de una implementación particular. Escalan bien: streaming (un pase, memoria fija), PageRank/HITS/Louvain (lineales en aristas, paralelizables estilo Pregel), K-Means mini-batch, TF-IDF ralo y SVD truncada/aleatorizada [10].

B. Sesgos: quién produce la señal

Todos los modelos aprenden de las reseñas, y la señal está concentrada: el **88.1% de los usuarios escribió una sola reseña**, la élite de Yelp (16.5% de usuarios) produce el 25% de las reseñas, y del lado de los negocios el Gini es 0.666: el top 1% concentra el 17.9% de las reseñas y un 34.2% tiene menos de 10. Consecuencias medidas en el propio pipeline: el clustering usa `log_reviews/log_checkins` como features, así que los negocios poco reseñados caen a clusters de “baja señal” no por ser peores sino por invisibles; PageRank correlaciona 0.977 con las amistades (rich-get-richer) y HITS deja que la élite defina las authorities; y el CF requiere co-ratings que el 88% de los usuarios no puede aportar, de modo que reciben el top-popular —más exposición para los ya populares. El muestreo estratificado

controla el sesgo geográfico, pero *ningún ajuste posterior recupera a quienes no están en los datos*.

Reseñas falsas/spam: no se detectaron explícitamente, pero el pipeline muestra dónde golpearían y qué defensas naturales existen: los 190 outliers de DBSCAN son el lugar natural de auditoría; HITS es vulnerable a *link farms* (anillos de cuentas que se reseñan entre sí) mientras PageRank sobre amistades es más costoso de manipular; el *shilling* infla la similitud item-item del CF, y el filtro de ≥ 3 co-ratings sube el costo del ataque sin eliminarlo; el CMS nunca subestima, así que el spam solo infla frecuencias. Nótese la tensión: el 88% de usuarios con una reseña es estadísticamente indistinguible de cuentas descartables —toda defensa basada en historial castiga justo a los usuarios legítimos nuevos.

C. Equidad: cadenas, popularidad y diversidad

Usando como proxy de cadena los nombres con ≥ 5 locales en la muestra (Starbucks, McDonald's, Pizza Hut...):

TABLE IX: Cadenas vs negocios independientes

	n	Rating prom.	% abiertos
Independientes	2,808	3.63	78%
Cadenas (≥ 5 locales)	135	2.60	92%

En calidad percibida ganan los independientes con claridad; la ventaja de las cadenas es estructural (sobreviven más). **La elección de la métrica de ordenamiento es una decisión con consecuencias distributivas:** rankear por rating favorece a los pequeños, rankear por volumen o disponibilidad favorece a las cadenas. En recomendación, el top-popular ya logra $\text{NDCG@10} = 0.029$ (unas 20 veces el aleatorio) y el CF también favorece a los ítems con muchos ratings: el resultado es un *feedback loop* donde el 34% de negocios con < 10 reseñas prácticamente no puede entrar a un top-10. Mitigaciones compatibles con el pipeline: conservar el componente content-based (puntuía negocios con una sola reseña), re-ranquear el top- K con cuotas de diversidad y reservar posiciones de exploración, aceptando una pérdida medida de NDCG a cambio de un ecosistema menos concentrado. Finalmente, la personalización de calidad es para la minoría con historial; auditar métricas *por segmento* —y no solo en promedio— es la única forma de ver esa desigualdad.

IX. CONCLUSIONES

- Se construyó un pipeline coherente de punta a punta: la muestra estratificada de la Parte I alimenta grafos, clustering, recomendación, streaming y reducción de dimensionalidad, con artefactos intermedios reproducibles (semilla 42, parquet idempotentes).
- Implementar desde cero hizo medibles los tradeoffs: PageRank y Louvain revelan estructura social fuerte ($Q = 0.656$) que el conteo de reseñas no ve; K-Means++ segmenta mejor (0.167 vs 0.082 de silueta)

mientras DBSCAN aporta 190 outliers auditables; el CF item-item domina en exactitud ($\text{NDCG@10} = 0.070$) pero el content-based es el que cubre el cold-start del 88% de los usuarios.

- Los algoritmos de flujo cumplen sus garantías teóricas en la práctica: CMS dentro de la cota εN en el 100% de las claves con $\sim 8\times$ menos memoria, FM-LogLog con +4.5% de error usando 256 enteros. Son, junto con los métodos lineales en aristas y la SVD truncada, lo que escala a datos aún más masivos; las estructuras $O(n^2)$ (DBSCAN denso, silueta, layout) no.
- El sesgo dominante del dataset es de *participación*: una minoría escribe la realidad de la que aprenden todos los modelos y un tercio de los negocios es casi invisible. La equidad no se resuelve en el algoritmo sino en decisiones de diseño explícitas (qué métrica ordena, cuánta diversidad se inyecta, qué se audita por segmento).

APPENDIX A

GUÍA DE REPRODUCIBILIDAD

El repositorio contiene siete notebooks (proyecto2-datamining-p1 ...p7) que escriben sus módulos Python con `%writefile`, más la carpeta `artifacts/` con los parquet intermedios y un `README` con instrucciones y dependencias (numpy, pandas, matplotlib, pyarrow, kagglehub). Basta ejecutar los notebooks en orden dentro de una misma carpeta del Workspace: la Parte I descarga el dataset vía kagglehub (requiere token de Kaggle) y deja los artefactos; las Partes II–VII los reutilizan sin re-streamear. Todo se ejecutó en Databricks (Runtime 18 ML, Spark 4.1.0; driver Standard_E8ads_v7, 64 GB, 8 cores), con el cómputo en Python puro sobre el driver.

REFERENCES

- [1] Yelp Inc., “Yelp Open Dataset,” <https://business.yelp.com/data/resources/open-dataset/>.
- [2] L. Page, S. Brin, R. Motwani y T. Winograd, “The PageRank citation ranking: Bringing order to the Web,” Stanford InfoLab, 1999.
- [3] J. Kleinberg, “Authoritative sources in a hyperlinked environment,” *Journal of the ACM*, vol. 46, no. 5, pp. 604–632, 1999.
- [4] V. Blondel, J.-L. Guillaume, R. Lambiotte y E. Lefebvre, “Fast unfolding of communities in large networks,” *J. Stat. Mech.*, P10008, 2008.
- [5] D. Arthur y S. Vassilvitskii, “k-means++: The advantages of careful seeding,” en *Proc. SODA*, 2007, pp. 1027–1035.
- [6] M. Ester, H.-P. Kriegel, J. Sander y X. Xu, “A density-based algorithm for discovering clusters in large spatial databases with noise,” en *Proc. KDD*, 1996, pp. 226–231.
- [7] G. Cormode y S. Muthukrishnan, “An improved data stream summary: The count-min sketch and its applications,” *J. Algorithms*, vol. 55, no. 1, pp. 58–75, 2005.
- [8] P. Flajolet y G. N. Martin, “Probabilistic counting algorithms for data base applications,” *J. Comput. Syst. Sci.*, vol. 31, no. 2, pp. 182–209, 1985.
- [9] M. Durand y P. Flajolet, “Loglog counting of large cardinalities,” en *Proc. ESA*, 2003, pp. 605–617.
- [10] J. Leskovec, A. Rajaraman y J. Ullman, *Mining of Massive Datasets*, 3ra ed. Cambridge University Press, 2020.